

RAPPORT DE VEILLE TECHNOLOGIQUE

Thème : Le TinyML : l'intelligence artificielle au service de la sobriété numérique et de l'embarqué. **Cadre :** Épreuve de présentation du Portfolio – BTS SIO (Option SLAM)

1. Introduction & Problématique

Aujourd'hui, l'intelligence artificielle (IA) est omniprésente et transforme nos usages numériques. Cependant, cette révolution a un coût environnemental et infrastructurel majeur : elle repose majoritairement sur des architectures *Cloud* (serveurs distants) extrêmement gourmandes en énergie et en bande passante pour le traitement des données.

Face aux enjeux environnementaux actuels et à la nécessité de concevoir des solutions logicielles durables (Green IT), une nouvelle approche paradigmatique émerge : le **TinyML** (Tiny Machine Learning). Cette technologie consiste à exécuter des modèles d'intelligence artificielle directement sur des systèmes embarqués et des microcontrôleurs à très faible consommation énergétique.

Problématique : *Dans quelle mesure le TinyML permet-il de concilier les performances de l'intelligence artificielle avec la nécessité de réduire drastiquement la consommation énergétique et matérielle des systèmes informatiques ?*

2. Définition et Évolution Technologique

2.1. Qu'est-ce que le TinyML ?

Le TinyML est l'intersection entre le Machine Learning et les systèmes embarqués (IoT). Là où une IA classique nécessite d'envoyer les données (voix, image, température) vers le Cloud pour être traitées avant de recevoir une réponse, le TinyML effectue ce traitement **localement** (Edge Computing extrême).

Comparatif d'architecture :

- **IA Classique (Cloud)** : Acquisition → Transmission réseau → Calcul Cloud → Retour réseau → Action. (*Lent, énergivore, dépendant du réseau*).
- **TinyML (Local)** : Acquisition → Calcul sur puce locale → Action. (*Temps réel, économe, autonome*).

2.2. Une évolution logique de l'écosystème

L'architecture des systèmes intelligents a connu trois phases majeures :

1. **Cloud Computing** : Centralisation totale de la puissance de calcul.
2. **Edge Computing** : Rapprochement du calcul vers des passerelles locales (routeurs, serveurs de proximité).
3. **TinyML** : Décentralisation totale et exécution ultra-optimisée au plus près du capteur (microcontrôleur).

Cette bascule est aujourd'hui rendue possible grâce à la miniaturisation matérielle, mais surtout grâce à l'optimisation logicielle et algorithmique, permise par des frameworks spécialisés comme *TensorFlow Lite Micro*.

3. Architecture Logicielle et Innovations Techniques

En tant que futur développeur (SLAM), l'intérêt du TinyML réside dans l'optimisation extrême du code et des modèles pour qu'ils tiennent dans des mémoires ultra-réduites (parfois moins de 256 Ko de RAM).

3.1. Le Pipeline TinyML

Le flux de traitement d'une application TinyML se décompose ainsi :

1. **Acquisition** : Récupération brute via capteurs (micro, caméra).
2. **Prétraitement** : Nettoyage et réduction de la dimensionnalité des données pour alléger la charge de calcul.
3. **Inférence locale** : Exécution du modèle d'IA compressé.
4. **Action** : Prise de décision immédiate sur le microcontrôleur.

3.2. Les clés de l'optimisation algorithmique

Pour faire fonctionner ces réseaux de neurones sur des architectures limitées, plusieurs innovations techniques sont requises :

- **La Quantification (Quantization)** : C'est un processus de compression mathématique. On réduit la précision des poids du modèle (par exemple, passage de nombres flottants 32 bits à des entiers 8 bits). Cela divise la taille du modèle par 4 et réduit drastiquement la consommation CPU, avec une perte de précision négligeable.
 - **L'Élagage (Pruning)** : Cette technique consiste à identifier et supprimer les connexions (neurones) inutiles ou redondantes au sein du réseau, allégeant ainsi le modèle final.
 - **Inférence hors-ligne** : En éliminant les requêtes HTTP/TCP vers des serveurs, on supprime la latence réseau et on économise l'énergie massivement consommée par les modules Wi-Fi/4G.
-

4. Domaines d'Application et Cas Concrets

Le TinyML permet de rendre "intelligents" des objets qui ne pouvaient pas l'être auparavant en raison de contraintes de batterie ou de connectivité.

- **Domotique et IoT (Ex : "Hey Google")** : Un cas d'usage classique. Le micro écoute en permanence, mais l'analyse du mot-clé de déclenchement se fait via TinyML localement. L'appareil ne se connecte au Cloud (et ne consomme de l'énergie) que lorsque le mot-clé est détecté localement.
 - **Santé connectée (Smartwatches)** : Analyse du rythme cardiaque ou détection d'arythmie directement sur la puce de la montre. Les données médicales critiques ne transitent pas sur le réseau, garantissant ainsi le respect de la vie privée.
 - **Industrie 4.0** : Détection d'anomalies vibratoires sur les chaînes de production pour la maintenance prédictive, sans nécessiter de câblage réseau complexe.
 - **Agriculture de précision** : Capteurs autonomes placés dans des champs ou vignobles pour analyser l'humidité et optimiser l'irrigation, fonctionnant pendant des mois sur une simple pile bouton.
-

5. Bilan et Analyse Critique

L'intégration du TinyML représente une avancée majeure pour l'ingénierie logicielle durable. Son impact est à la fois économique (réduction des coûts d'infrastructure serveur), technique (autonomie des systèmes) et écologique (baisse drastique de l'empreinte carbone liée au transfert de données).

Cependant, comme toute technologie, elle présente un compromis entre performance et ressources.

Avantages majeurs :

- **Sobriété énergétique** : Consommation de l'ordre du milliwatt (< 1 mW).
- **Latence nulle** : Prise de décision en temps réel (ms).
- **Sécurité et Privacy** : Les données sensibles (voix, santé) restent sur l'appareil (Privacy by design).
- **Résilience** : Fonctionnement totalement hors-ligne.

Limites et défis de développement :

- **Contraintes de développement** : Nécessite une expertise pointue en optimisation logicielle (C/C++, gestion stricte de la mémoire).
 - **Capacité restreinte** : Les modèles complexes (comme les LLM) sont impossibles à embarquer ; le TinyML est réservé à des tâches de classification simples.
 - **Maintenance applicative** : La mise à jour de modèles sur des milliers d'appareils non connectés pose un défi logistique.
-

6. Conclusion

Le TinyML illustre parfaitement la transition vers une informatique plus efficiente. Alors que la tendance générale pousse vers des modèles toujours plus colossaux hébergés dans le Cloud, le TinyML prouve qu'une intelligence artificielle locale, frugale et hyper-optimisée est possible. En tant que développeur de solutions logicielles (SLAM), maîtriser ces concepts d'optimisation algorithmique et d'éco-conception est devenu un atout indispensable pour répondre aux défis numériques et écologiques de demain.